4112056012 多元線性回歸分析報告

一、資料集來源

本作業選用 Kaggle 上的 Red Wine Quality 資料集，進行多元線性回歸分析。

- 資料集名稱：Red Wine Quality
- Kaggle 來源：https://www.kaggle.com/datasets/uciml/red-wine-quality-cortez-et-al-2009
- 分析任務：使用紅酒的化學檢測數值預測品質分數 `quality`
- 特徵數：11 個
- 目標欄位： `quality`
- 模型類型：Multiple Linear Regression

選擇此資料集的原因是它具有 11 個輸入特徵，符合本作業要求的 10 至 20 個 features，且目標欄位 `quality` 可以視為數值型預測目標，因此適合使用線性回歸進行分析。資料中的特徵皆為紅酒化學檢測數值，例如酸度、糖分、氯化物、密度、pH、硫酸鹽與酒精濃度，能夠用來探討化學特徵與品質分數之間的關係。

此資料集源自 Wine Quality 相關研究資料，常被用於機器學習教學與品質預測練習。由於它不是 Kaggle competition 類型資料集，因此本作業沒有 Kaggle 排名可呈現，改以測試集預測結果、評估指標與預測區間圖作為模型成果呈現。

二、CRISP-DM 分析流程

1. Business Understanding

本分析的目標是根據紅酒的化學成分預測品質分數。紅酒品質通常受到酸度、酒精濃度、硫酸鹽、密度等因素影響，若能透過模型找出與品質較相關的特徵，便可協助品質管理人員進行初步判斷。

此分析不取代專業品酒評分，而是提供一個以數據為基礎的輔助評估方式。透過多元線性回歸，可以建立一個容易解釋的基準模型，觀察不同化學指標與紅酒品質分數之間的整體關係。

2. Data Understanding

資料集共有 1599 筆資料與 12 個欄位，其中 11 個欄位為輸入特徵，1 個欄位為預測目標 `quality` 。輸入特徵如下：

```
fixed acidity
volatile acidity
citric acid
residual sugar
chlorides
free sulfur dioxide
total sulfur dioxide
density
pH
sulphates
alcohol
```

程式檢查後發現所有欄位皆無缺失值，因此不需要額外進行遺漏值補值。資料理解階段也透過相關係數熱圖觀察各特徵與品質分數之間的關係，作為後續特徵選擇與模型解讀的參考。

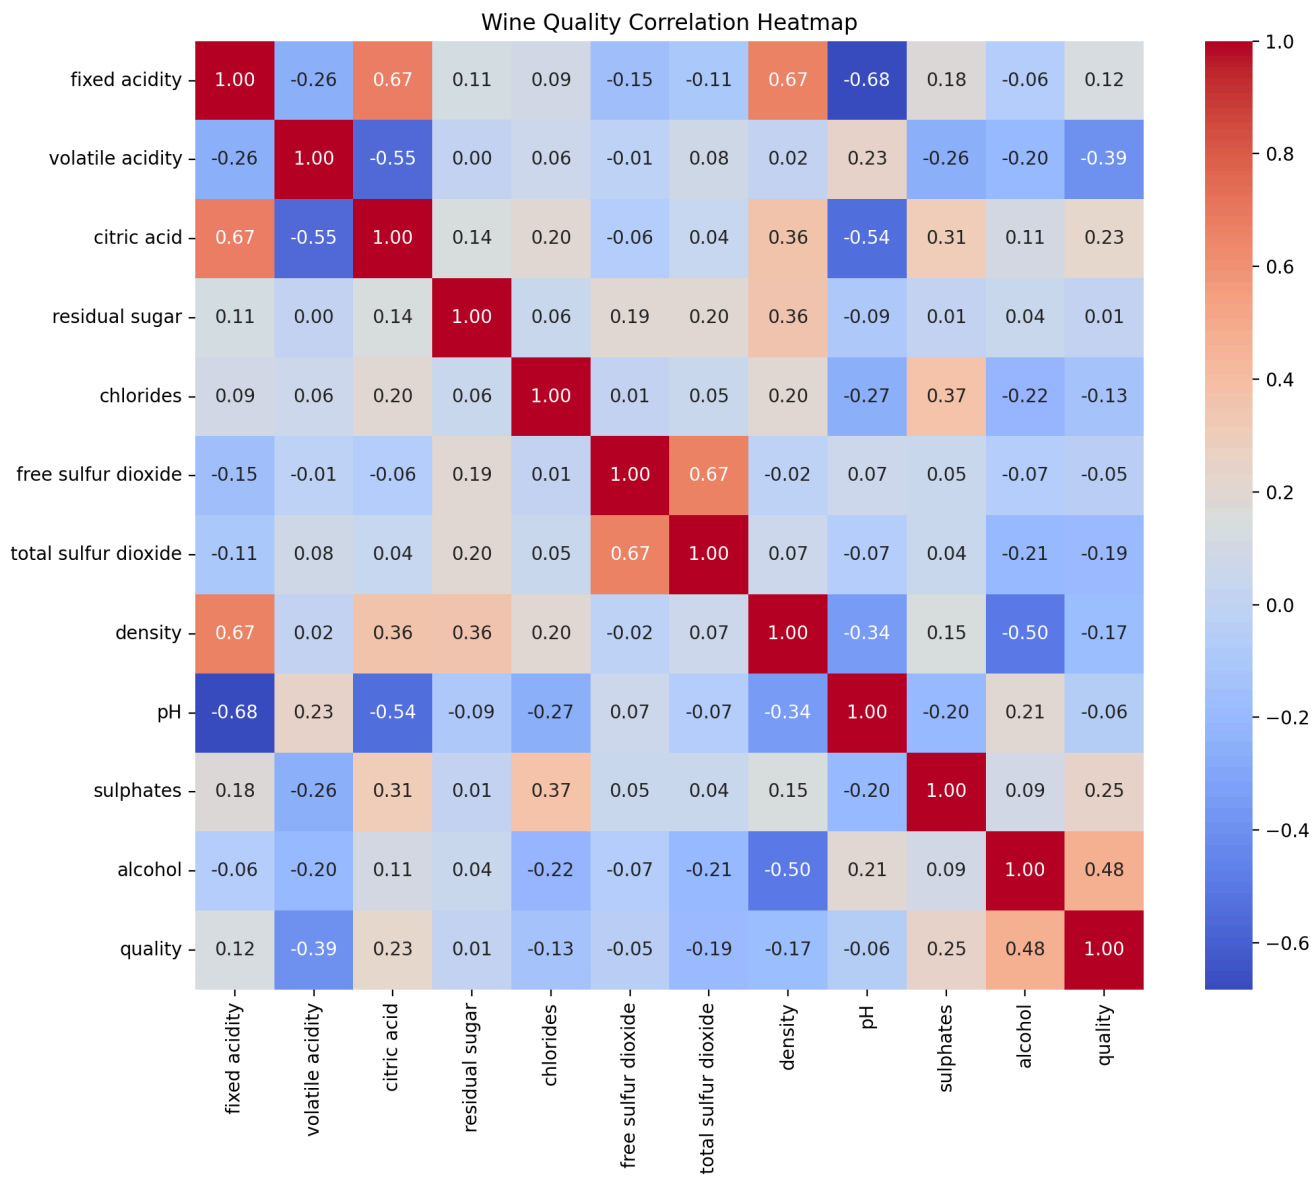

圖 1 呈現各項紅酒化學特徵與品質分數之間的相關程度，可用來觀察哪些變數較可能影響品質分數。顏色越接近紅色代表正相關越強，越接近藍色代表負相關越強。此圖能輔助後續特徵選擇，也讓資料理解階段更直觀。

3. Data Preparation

資料準備包含以下步驟：

1. 讀取 `winequality-red.csv`
2. 確認資料欄位、資料筆數與缺失值
3. 將 `quality` 設為預測目標
4. 將其餘 11 個欄位設為輸入特徵
5. 使用 train-test split 切分訓練集與測試集
6. 使用 StandardScaler 進行特徵標準化

本作業將 80% 資料作為訓練集，20% 資料作為測試集，並設定固定 random state，確保每次執行程式都能得到一致的資料切分結果。

4. Modeling

本作業建立兩個線性回歸模型進行比較。

第一個模型使用全部 11 個特徵建立 Linear Regression，作為基準模型。第二個模型使用 SelectKBest 搭配 `f_regression` 進行特徵選擇，挑選前 8 個與目標變數較相關的特徵，再建立 Linear Regression 模型。

SelectKBest 選出的 8 個特徵如下：

```
fixed acidity
volatile acidity
citric acid
chlorides
total sulfur dioxide
density
sulphates
alcohol
```

特徵選擇圖輸出檔案：

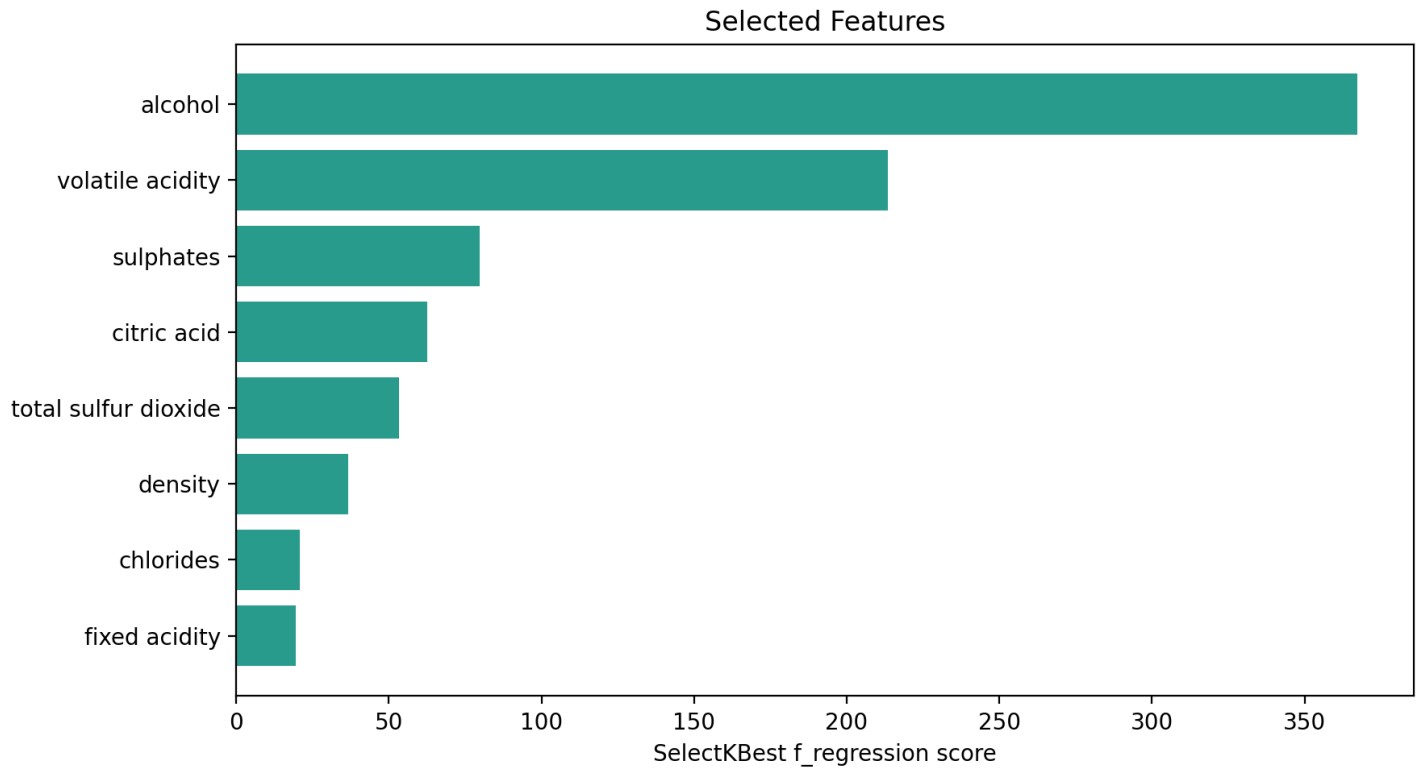

圖 2 顯示 SelectKBest 挑選出的主要特徵與其分數。由圖中可以看出，部分化學特徵對品質分數具有較高解釋力，因此特徵選擇不只可以簡化模型，也能協助說明哪些變數對預測較有貢獻。

5. Evaluation

本作業使用 MAE、RMSE 與 R2 評估模型表現。

Model	MAE	RMSE	R2
Linear Regression - all features	0.5035	0.6245	0.4032
Linear Regression - top 8 selected features	0.5062	0.6265	0.3993

從結果可以看出，使用全部特徵的模型 R2 約為 0.4032，略高於特徵選擇後的模型。這表示在本次資料切分與模型設定下，全部特徵模型的解釋能力稍好。不過兩者差距不大，代表特徵選擇後仍能保留大部分預測能力，且模型更簡潔。

MAE 約為 0.50，代表模型預測的品質分數平均誤差約為半分左右。RMSE 約為 0.62，表示考慮較大誤差後，整體誤差仍落在可討論範圍內。R2 約為 0.40，代表線性模型可以解釋部分品質變異，但仍有許多因素無法被單純線性關係完整捕捉。

本作業也輸出實際值與預測值比較圖，並加入約 95% 預測區間，用來呈現模型預測的不確定性。預測圖輸出檔案如下：

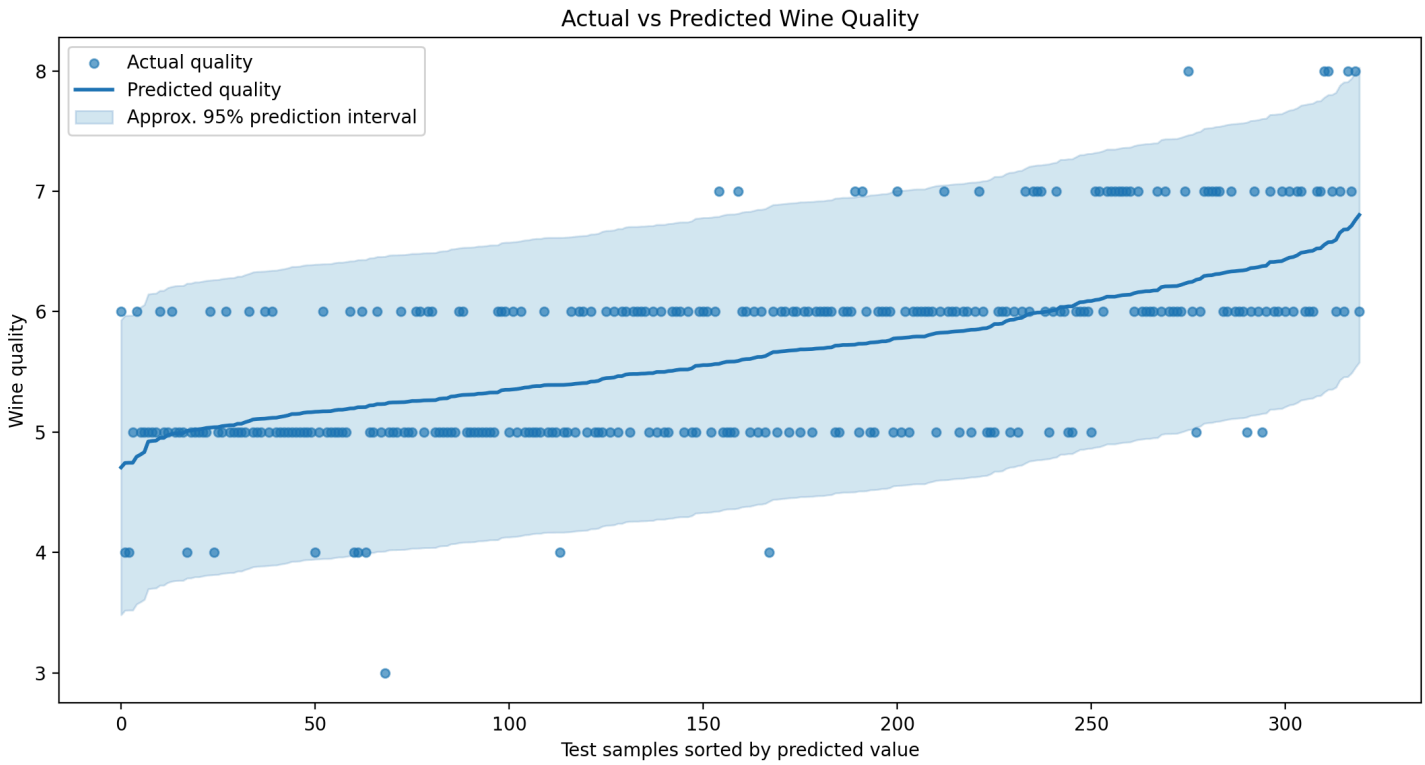

圖 3 顯示使用全部 11 個特徵時，測試資料的實際品質分數、模型預測分數，以及約 95% 預測區間。多數實際值落在預測區間附近，表示模型雖然無法完全精準預測每一筆樣本，但整體預測趨勢仍具參考價值。

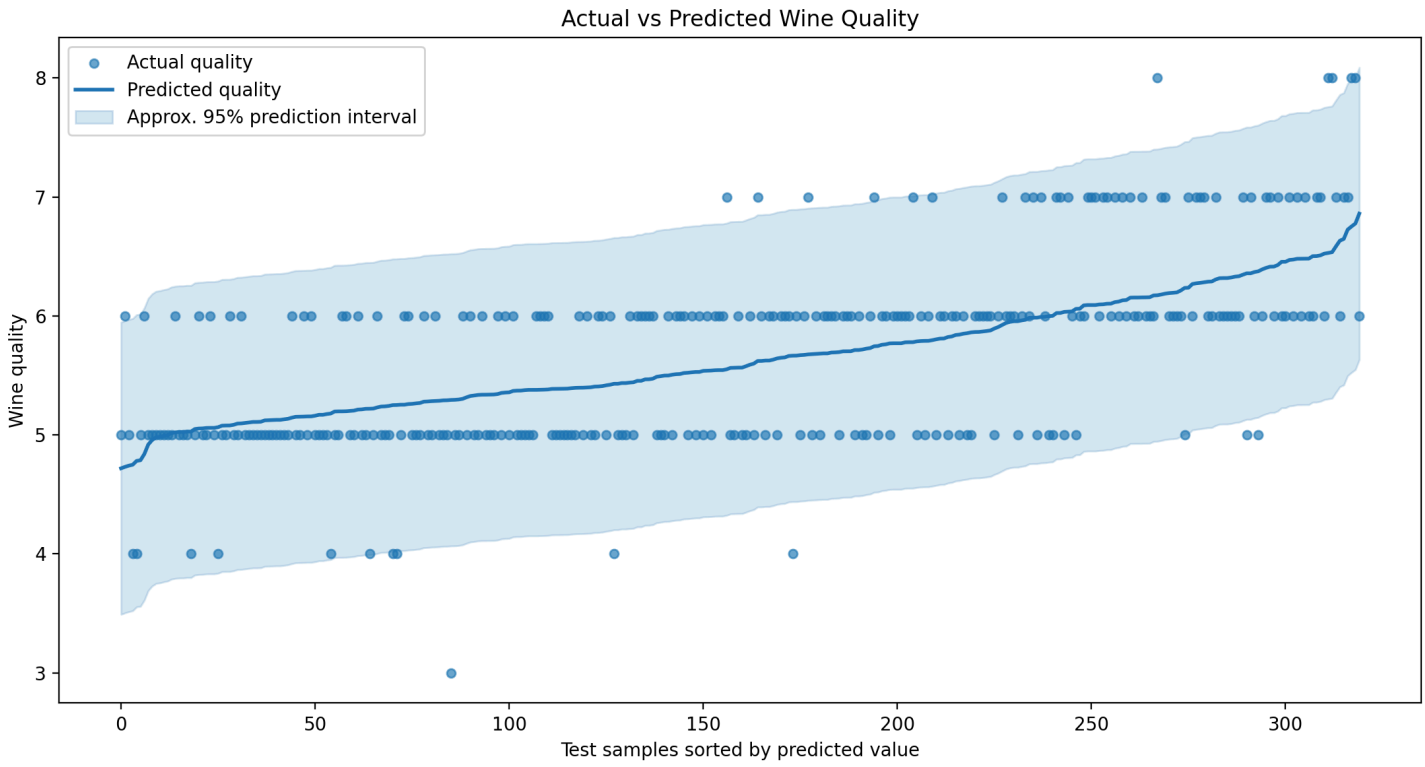

圖 4 顯示只使用 SelectKBest 選出的 8 個特徵時的預測結果。與全部特徵模型相比，兩者圖形趨勢相近，表示特徵選擇後仍保留主要預測資訊。這也使模型更簡潔，方便在報告中說明模型解釋性與預測表

現之間的取捨。

6. Deployment

若要將此模型應用於實際情境，可設計為一個紅酒品質預測流程。使用者輸入紅酒的化學檢測數值後，模型輸出預測品質分數，並搭配模型誤差與預測區間提供參考。

實務上仍建議搭配人工品評與更多非化學特徵，例如產地、年份、釀造方式、儲存條件與品酒者評分標準等資料，以提升判斷準確度。此模型較適合作為初步品質評估或資料分析教學範例，而不是完整取代實際酒品評鑑流程。

三、GPT 輔助內容

本作業使用 ChatGPT / Codex 協助閱讀作業說明、整理作業需求、建立 README、選擇 Kaggle 資料集、建立 Python 分析程式、執行模型分析、整理模型結果，以及產生報告草稿。

GPT 輔助內容主要包含：

1. 整理 `HW_description.txt` 中的作業要求
2. 建立 `ASSIGNMENT_REQUIREMENTS.md`
3. 建立 `README.md`
4. 選擇 Red Wine Quality 作為 Kaggle 資料集
5. 撰寫 `4112056012_hw2.py`
6. 建立特徵選擇與模型評估流程
7. 產生預測圖與約 95% 預測區間
8. 建立 NotebookLM 使用資料包
9. 整合 NotebookLM 回覆並完成報告

聊天紀錄已整理於 `chat.md` 。正式繳交時，需將聊天紀錄匯出為 PDF，作為 GPT 對話過程附件。

四、NotebookLM 摘要

根據 NotebookLM 對於 Kaggle 上的 Red Wine Quality 資料集與相關分析資料的研究整理，本資料集的研究目的在於透過紅酒的化學檢測數值來預測其品質分數，以協助理解哪些化學指標與品質評分最為相關。在特徵重要性的分析中，常見的關鍵特徵包含酒精濃度 (alcohol)、揮發性酸度 (volatile acidity) 以及硫酸鹽 (sulphates) 等數值。本分析選用線性回歸 (Linear Regression) 作為基準模型，主要是因為其具備高度的可解釋性，能透過相關係數與模型係數直觀地解釋各種化學檢測數值對品質的影響。然而，這類模型在該資料集上的解釋力，也就是 R2 值，通常不會太高，主要是因為紅酒品質的分數帶有主觀

評分成分，且可能受到化學數值以外的其他因素影響。雖然單純線性回歸的解釋能力有限，但它為後續應用可能有更好表現的複雜模型奠定了良好的評估基礎。

五、網路主流或更優解法比較

在 NotebookLM 針對網路上常見的 Wine Quality 類型問題解法整理中，除了線性回歸，資料科學社群常使用的進階解法包含 Random Forest、Gradient Boosting 與 XGBoost 等模型。此外，也有許多解法會將原本的數值預測轉換為分類模型，將品質直接區分為低、中、高等級來進行分析。

比較這些方法與線性回歸的差異，線性回歸的優點在於模型極為簡單且可解釋性強，因此非常適合作為預測任務的 baseline。不過，線性回歸的限制在於它難以有效捕捉變數之間複雜的非線性關係。相對地，tree-based models 的優點是能處理非線性與特徵之間的交互作用，通常在預測表現上會更為優異。

儘管進階模型的準確率可能較高，但考量到本作業的核心重點在於演練多元線性回歸分析並完整落實 CRISP-DM 流程，因此本專案仍維持以 Linear Regression 作為主要模型，並透過特徵選擇與加入預測區間來強化整體分析的完整性與說服力。

六、結論

本作業使用 Red Wine Quality 資料集建立多元線性回歸模型，並依照 CRISP-DM 流程完成資料理解、資料準備、建模、特徵選擇、模型評估與部署情境說明。模型結果顯示，使用全部 11 個特徵的 Linear Regression 模型略優於 SelectKBest 選出 8 個特徵後的模型，但兩者差距不大。

整體而言，線性回歸能提供清楚且容易解釋的基準結果，但由於紅酒品質評分本身帶有主觀因素，且可能存在非線性關係，因此模型的 R2 約為 0.40 屬於合理結果。若未來要追求更高預測表現，可以進一步嘗試 Random Forest、Gradient Boosting、XGBoost，或將品質分數轉換為分類任務進行分析。

從結果呈現來看，本報告除了列出 MAE、RMSE 與 R2 等評估指標，也加入相關係數熱圖、特徵選擇圖與預測區間圖，使模型結果能同時以數值與視覺化方式呈現。這些圖表能補強模型解釋性，讓分析結果更清楚，也更符合「結果合理、美觀且具有說服力」的評分要求。

七、輸出檔案

程式執行後產生以下輸出：

```
outputs/model_metrics.csv
outputs/selected_features.csv
outputs/correlation_heatmap.png
outputs/selected_features.png
outputs/prediction_interval_all_features.png
outputs/prediction_interval_selected_features.png
```

八、評分標準對照

評分項目	本報告對應內容	完成狀態
CRISP-DM 流程完整且邏輯清楚	第二章依序說明 Business Understanding、Data Understanding、Data Preparation、Modeling、Evaluation、Deployment	已完成
包含 GPT 對話與 NotebookLM 摘要	第三章標示 GPT 輔助內容，第四章放入 NotebookLM 摘要，另有 `chat.md` 與 `chat.pdf`	已完成
明確說明資料集來源與研究脈絡	第一章列出 Kaggle 來源、資料集背景、特徵數、預測目標與選擇原因	已完成
模型正確可執行， 具特徵選擇與評估	`4112056012_hw2.py` 可執行，使用 SelectKBest 特徵選擇，並以 MAE、RMSE、R2 評估	已完成
結果合理、美觀且具有說服力	報告嵌入相關係數熱圖、特徵選擇圖、 預測區間圖，並搭配文字解釋模型結果	已完成
Kaggle 名次或預測結果評估	本資料集非 competition，無 Kaggle 名次； 本報告改呈現預測圖、約 95% 預測區間與評估指標	已完成

正式繳交建議包含：

```
4112056012_hw2.py
4112056012_report.pdf
GPT_chat.pdf
README.md
requirements.txt
data/winequality-red.csv
outputs/
```